

项目背景

2023年第十八届“挑战杯”全国大学生课外学术科技作品竞赛“揭榜挂帅”专项赛

推报学校名称：浙江工商大学

参加竞榜的选题发榜单位：中国软件与技术服务股份有限公司

参加竞榜的选题名称：基于信创的学习迁移模型构建知识图谱

申报作品具体名称：融智图谱——学习迁移模型构建知识图谱

负责人：冉熙 19143656913

使用说明

针对源代码的使用说明

环境配置

建议创建一个python3.8的虚拟环境，可能需要安装[Rust Compiler](#)

首先需要安装CUDA和PaddlePaddle(飞桨)框架：

- [从零开始配置深度学习环境：CUDA+Anaconda+Pytorch+TensorFlow - 孤飞 - 博客园 \(cnblogs.com\)](#)
- [安装飞桨框架-源于产业实践的开源深度学习平台 \(paddlepaddle.org.cn\)](#)

针对 CUDA 11.6 我们第一步首先在终端运行以下代码：

```
pip install paddlepaddle-gpu==2.5.1.post116 -f
https://www.paddlepaddle.org.cn/whl/windows/mkl/avx/stable.html
```

然后安装 PaddleNLP：

```
pip install paddlenlp -i http://mirrors.aliyun.com/pypi/simple/ --trusted-host
mirrors.aliyun.com
```

以及安装 Pytorch：

```
pip install torch==1.13.1+cu116 torchvision==0.14.1+cu116 torchaudio==0.13.1 --
extra-index-url https://download.pytorch.org/whl/cu116
```

安装 transformers：

```
pip install transformers -i http://mirrors.aliyun.com/pypi/simple/ --trusted-host
mirrors.aliyun.com
```

项目架构

--揭榜挂帅

--data-final：最终数据集（分为policy和news的train和test）格式为重新按照句子分段的txt

```
--data-origin: 原始提供的多模态数据
--data-preprocess: 转换多模态数据为txtline数据格式脚本
    --other-to-txt: 第一步: 将各种数据格式文件转换为txt文件
    --txt-resegment: 第二步: 将所有的txt文件重新分句, 使得每个段落(\n)不至于太长。
    --train-test-split: 第三步: 将所有txt文件分为训练集和测试集
--data-preprocessed: 多模态数据转化后的txt格式的数据集
    --new-news: 包含从wps、pdf和docx转换的txt文件
    --new-policy: 原本的txt文件, 因为policy只有txt文件
--dataset-develop: 用于开发更多功能的数据生成脚本
    --batch-result-api.py: 在后端等待并直接输出算法结果的api, 可以批量输出
    --batch-result-save.py: 调用后端输出的api, 批量输入txt获得算法结果
--mixed-filter: 用于过滤输出结果, 混合过滤器提升模型最终结果准确性
--presentation: 交互式前端展示, html, api和css
    --back-end-api.py: 后端api, 先运行在888端口
    --presentation.html: 前端展示实体识别和关系提取代码, 可以调用后端api
--sentence-completion: 知识框架补全部分, 实现句子补全
--uie-model: 基于飞桨UIE模型的迁移微调信息抽取模型
    --checkpoint: 模型微调后模型保存到的目录
        --model_best4000: 最终提交的模型文件目录, 包含12个模型文件
    --data: 放置用于测试、模型微调训练的数据文件
        --doccano_ext.json: 其中只用放置这个标注的数据集文件, 其余文件通过tran.sh脚本生成
    --deploy: UIE模型部署到服务器的基础代码目录, 不需要修改
    --train.sh: 从本目录下的data数据集获取train.txt数据进行模型微调训练脚本
    --tran.sh: 将doccano_ext.json文件转换为train.txt、test.txt、name.txt、dev.txt
    --model_evaluation: 测试全部类型的实体与关系的准确率和召回率的脚本
    --model_debug.sh: 测试各个类型的实体和关系的精确率和召回率的脚本
    --其余py文件: 模型训练与测试等代码不用修改
--autoapi.py: 在服务器上提供api, 通过接口访问模型并返回预测结果的脚本
--localtest.py: 在本地对事先输入的文本进行预测并返回预测结果的脚本
--requirements.txt: 运行项目需要安装的Python库
```

模型微调（训练）

1. 准备好标注好的数据 `doccano_ext.json`, 放进 `uie-model` 目录下的 `data` 文件夹内
2. 运行 `tran.sh`, 就会将从 `doccano` 导出的标注数据转化为模型的输入数据和测试数据
3. 运行 `train.sh`, 就可以开始训练 `uie-base` 模型, 训练结束后会保存模型到 `checkpoint` 目录下的 `model_best` 路径下, `train.sh` 可以根据自己的需求修改参数。

模型下载（paddle与torch模型）

由于github等版本控制工具仓库有大文件限制, 且模型文件通过git传输较慢, 故将模型上传至百度网盘。提供了直接拷贝整个项目之外的快速传输方案。

将下载的压缩包解压后复制当前目录不存在的模型目录即可。

文件: `model-best4000.rar`、`uie-pytorch.rar`、`docker.rar`

链接: <https://pan.baidu.com/s/1CLdcpnjk2CEDh0tZvZV6RA?pwd=czci>
提取码: czci

模型测试

整体模型性能测试

运行 `model_evaluation.sh`，就可以开始测试整个模型的精确率、召回率了，本模型的 `F1-Score` 能够达到97%，**三项指标性能均超过95%**满足题目要求。

```
[2023-09-11 21:11:16,181] [ INFO] - -----
[2023-09-11 21:11:16,181] [ INFO] - Class Name: all_classes
[2023-09-11 21:11:16,181] [ INFO] - Evaluation Precision: 0.95353 | Recall: 0.98752 | F1: 0.97023
```

各类实体和关系性能测试

运行 `model_debug.sh`，就可以开始测试整个模型的精确率，召回率了，

实体识别精确率、召回率、F1-Score均高于95%.

```
[2023-09-11 21:22:53,965] [ INFO] - -----
[2023-09-11 21:22:53,965] [ INFO] - Class Name: 人名
[2023-09-11 21:22:53,966] [ INFO] - Evaluation Precision: 1.00000 | Recall: 1.00000 | F1: 1.00000
[2023-09-11 21:22:55,513] [ INFO] - -----
[2023-09-11 21:22:55,513] [ INFO] - Class Name: 城市地点
[2023-09-11 21:22:55,513] [ INFO] - Evaluation Precision: 1.00000 | Recall: 0.99123 | F1: 0.99559
[2023-09-11 21:22:56,098] [ INFO] - -----
[2023-09-11 21:22:56,099] [ INFO] - Class Name: 政策
[2023-09-11 21:22:56,099] [ INFO] - Evaluation Precision: 1.00000 | Recall: 0.96774 | F1: 0.98361
[2023-09-11 21:22:57,590] [ INFO] - -----
[2023-09-11 21:22:57,590] [ INFO] - Class Name: 事件工程项目
[2023-09-11 21:22:57,591] [ INFO] - Evaluation Precision: 1.00000 | Recall: 0.99029 | F1: 0.99512
[2023-09-11 21:22:59,677] [ INFO] - -----
[2023-09-11 21:22:59,678] [ INFO] - Class Name: 组织机构企业
[2023-09-11 21:22:59,678] [ INFO] - Evaluation Precision: 1.00000 | Recall: 0.95706 | F1: 0.97806
[2023-09-11 21:23:00,094] [ INFO] - -----
[2023-09-11 21:23:00,094] [ INFO] - Class Name: 国家
[2023-09-11 21:23:00,095] [ INFO] - Evaluation Precision: 1.00000 | Recall: 1.00000 | F1: 1.00000
[2023-09-11 21:23:01,718] [ INFO] - -----
[2023-09-11 21:23:01,718] [ INFO] - Class Name: 政府机构
[2023-09-11 21:23:01,718] [ INFO] - Evaluation Precision: 1.00000 | Recall: 1.00000 | F1: 1.00000
[2023-09-11 21:23:02,239] [ INFO] - -----
[2023-09-11 21:23:02,239] [ INFO] - Class Name: 省份
[2023-09-11 21:23:02,239] [ INFO] - Evaluation Precision: 0.96875 | Recall: 0.96875 | F1: 0.96875
[2023-09-11 21:23:02,788] [ INFO] - -----
[2023-09-11 21:23:02,788] [ INFO] - Class Name: 会议
[2023-09-11 21:23:02,789] [ INFO] - Evaluation Precision: 1.00000 | Recall: 0.97297 | F1: 0.98630
[2023-09-11 21:23:03,173] [ INFO] - -----
[2023-09-11 21:23:03,173] [ INFO] - Class Name: 新闻杂志融媒体
[2023-09-11 21:23:03,173] [ INFO] - Evaluation Precision: 1.00000 | Recall: 1.00000 | F1: 1.00000
[2023-09-11 21:23:03,224] [ INFO] - -----
[2023-09-11 21:23:03,225] [ INFO] - Class Name: 法规条例
[2023-09-11 21:23:03,225] [ INFO] - Evaluation Precision: 1.00000 | Recall: 1.00000 | F1: 1.00000
[2023-09-11 21:23:03,253] [ INFO] - -----
[2023-09-11 21:23:03,254] [ INFO] - Class Name: X的代称
[2023-09-11 21:23:03,254] [ INFO] - Evaluation Precision: 1.00000 | Recall: 1.00000 | F1: 1.00000
[2023-09-11 21:23:03,918] [ INFO] - -----
```

关系提取准确率（指F1Score） 仅有1/7个(政策的针对地区)低于95%，其余均高于95%

```
[2023-09-11 21:23:03,918] [ INFO] - -----
[2023-09-11 21:23:03,919] [ INFO] - Class Name: X的隶属
[2023-09-11 21:23:03,919] [ INFO] - Evaluation Precision: 1.00000 | Recall: 0.95455 | F1: 0.97674
[2023-09-11 21:23:04,586] [ INFO] - -----
[2023-09-11 21:23:04,586] [ INFO] - Class Name: X的身份
[2023-09-11 21:23:04,586] [ INFO] - Evaluation Precision: 1.00000 | Recall: 0.97222 | F1: 0.98592
[2023-09-11 21:23:04,753] [ INFO] - -----
[2023-09-11 21:23:04,753] [ INFO] - Class Name: X的发言人
[2023-09-11 21:23:04,753] [ INFO] - Evaluation Precision: 1.00000 | Recall: 1.00000 | F1: 1.00000
[2023-09-11 21:23:04,866] [ INFO] - -----
[2023-09-11 21:23:04,866] [ INFO] - Class Name: X的发布单位
[2023-09-11 21:23:04,866] [ INFO] - Evaluation Precision: 1.00000 | Recall: 1.00000 | F1: 1.00000
[2023-09-11 21:23:04,897] [ INFO] - -----
[2023-09-11 21:23:04,898] [ INFO] - Class Name: X的发布内容
[2023-09-11 21:23:04,898] [ INFO] - Evaluation Precision: 1.00000 | Recall: 1.00000 | F1: 1.00000
[2023-09-11 21:23:05,037] [ INFO] - -----
[2023-09-11 21:23:05,038] [ INFO] - Class Name: X的针对地区
[2023-09-11 21:23:05,038] [ INFO] - Evaluation Precision: 0.87500 | Recall: 1.00000 | F1: 0.93333
[2023-09-11 21:23:05,068] [ INFO] - -----
[2023-09-11 21:23:05,068] [ INFO] - Class Name: X的开会地点
[2023-09-11 21:23:05,068] [ INFO] - Evaluation Precision: 1.00000 | Recall: 1.00000 | F1: 1.00000
```

参数调整

参数调整请看UIE模型的参数介绍文档：[./uie-model/README.md](#)

或者在线版：[PaddleNLP/README.md at develop · PaddlePaddle/PaddleNLP \(github.com\)](#)

有关doccano协同标注平台搭建，AIStudio 使用A100 GPU训练项目可以联系我：19143656913

部署说明

后端api已经打包至docker，具体使用说明请看说明文档：[Docker后端使用说明](#)

前端静态网页提供完整直接可部署的文件夹，具体使用说明请看说明文档：[nginx前端使用说明](#)